

Documentación del Proyecto

Fase 1: Base de Datos

Olimpiadas (1896 - 2024)

Universidad de San Carlos de Guatemala

Facultad de Ingeniería - Escuela de Ciencias y Sistemas

Sistemas de Bases de Datos 2 - 2do. Semestre 2026

Grupo: #16

Integrantes:

- Marcelo André Juárez Alfaro - 202010367
- Carlos David de León Barrios - 202112109
- Angel Rafael Barrios González - 202300733

1. Introducción y Alcance

El presente proyecto tiene como objetivo la integración, limpieza y consolidación de la información histórica de los Juegos Olímpicos desde Atenas 1896 hasta París 2024. Los datos provienen de cuatro fuentes heterogéneas principales: repositorios de Kaggle, datasets de Keith Galli y DataCamp, tomando como validación de calidad el sitio oficial olympics.com. La arquitectura de solución emplea Python (mediante Jupyter Notebooks) para los procesos de Extracción, Transformación y Carga (ETL) desde los archivos crudos, y Microsoft SQL Server para el alojamiento, persistencia y consulta analítica de la base de datos relacional resultante.

2. Modelo Entidad-Relación (ER)

El modelado de datos se diseñó bajo un enfoque relacional pragmático orientado a esquema de estrella/copo de nieve, minimizando la hiper-normalización para evitar uniones (**JOIN**) excesivas y garantizando la integridad referencial.


El núcleo del modelo es la tabla central de hechos **PARTICIPACION**, la cual se encuentra rodeada por entidades dimensionales maestras: **ATLETA**, **PAIS**, **SEDE**,

EDICION_JUEGOS, EVENTO, DEPORTE, POBLACION_PAIS y FUENTE_DATOS.

DIAGRAMA ER

GRUPO #16

Marcelo Andres Juarez Alfaro
Carlos David de León Barrios
Angel Rafael Barrios González



3. Proceso ETL y Limpieza de Datos

La limpieza de la información cruda se gestionó mediante los archivos `etl_carga.ipynb` y `auditoria.ipynb`, resolviendo los siguientes desafíos críticos de los datos origen:

- Resolución de Colisiones de Identificadores:** Debido a que distintas fuentes (ej. Kaggle vs. Keith Galli) poseían diferentes atletas con el mismo `ID` original, se implementó un campo de llave primaria autoincremental (`id_atleta INT IDENTITY(1,1)`) en la tabla final, resguardando los códigos originales en columnas de trazabilidad (`id_origen_bios`, `id_origen_kaggle`).


- **Homologación de Códigos Geográficos:** Se integraron tanto los códigos internacionales de tres letras del Banco Mundial (`codigo_iso3`) como los del Comité Olímpico (`codigo_noc`) en la entidad `PAIS` para mantener la integridad relacional con las estadísticas de población y sedes.
- **Manejo de Valores Nulos:** Los datos faltantes de origen (estatura, peso, edad o género) se conservaron e ingresaron en la base de datos como valores `NULL` estrictos en lugar de cadenas vacías o ceros.

4. Implementación de Procedimientos Almacenados (Stored Procedures)

Se implementaron y compilaron en SQL Server los requerimientos analíticos solicitados en el enunciado:

4.1. Procedimiento: `sp_ConsultarAtleta`

Permite buscar un atleta por su nombre y muestra de manera unificada el país que representó, el año de edición, el deporte, la prueba específica y la medalla obtenida. Se incluyen parámetros opcionales para filtrar resultados por deporte, país o año.



```

USE OlimpiadasDB;
GO

-- PRUEBA DE STORED PROCEDURES (Para ejecutar en vivo)
-- Ejecutar buscando un atleta específico
EXEC sp_ConsultarAtleta @nombre_atleta = 'Michael Fred Phelps';


-- Ejecutar buscando un país (Ejemplo: Estados Unidos)
-- EXEC sp_ConsultarPais @codigo_o_nombre = 'USA';
  
```

IdAtleta	NombreAtleta	PaisRepresentado	AnioEdicion	Deporte	Prueba	MedallaObtenida
1	Michael Fred Phelps	USA	2000	Swimming	Swimming Men's 200 metres Butterfly	NULL
2	Michael Fred Phelps	USA	2004	Swimming	Swimming Men's 4 x 200 metres Freestyle Relay	Gold
3	Michael Fred Phelps	USA	2004	Swimming	Swimming Men's 400 metres Individual Medley	Gold
4	Michael Fred Phelps	USA	2004	Swimming	Swimming Men's 200 metres Butterfly	Gold
5	Michael Fred Phelps	USA	2004	Swimming	Swimming Men's 100 metres Butterfly	Gold
6	Michael Fred Phelps	USA	2004	Swimming	Swimming Men's 200 metres Individual Medley	Gold
7	Michael Fred Phelps	USA	2004	Swimming	Swimming Men's 200 metres Freestyle	Bronze
8	Michael Fred Phelps	USA	2004	Swimming	Swimming Men's 4 x 100 metres Freestyle Relay	Bronze
9	Michael Fred Phelps	USA	2004	Swimming	Swimming Men's 4 x 100 metres Medley Relay	Gold
10	Michael Fred Phelps	USA	2008	Swimming	Swimming Men's 4 x 200 metres Freestyle Relay	Gold
11	Michael Fred Phelps	USA	2008	Swimming	Swimming Men's 400 metres Individual Medley	Gold
12	Michael Fred Phelps	USA	2008	Swimming	Swimming Men's 200 metres Individual Medley	Gold
13	Michael Fred Phelps	USA	2008	Swimming	Swimming Men's 100 metres Butterfly	Gold
14	Michael Fred Phelps	USA	2008	Swimming	Swimming Men's 200 metres Freestyle	Gold
15	Michael Fred Phelps	USA	2008	Swimming	Swimming Men's 4 x 100 metres Freestyle Relay	Gold
16	Michael Fred Phelps	USA	2008	Swimming	Swimming Men's 200 metres Butterfly	Gold
17	Michael Fred Phelps	USA	2008	Swimming	Swimming Men's 4 x 100 metres Medley Relay	Gold
18	Michael Fred Phelps	USA	2012	Swimming	Swimming Men's 200 metres Individual Medley	Gold
19	Michael Fred Phelps	USA	2012	Swimming	Swimming Men's 100 metres Butterfly	Gold
20	Michael Fred Phelps	USA	2012	Swimming	Swimming Men's 4 x 100 metres Freestyle Relay	Silver
21	Michael Fred Phelps	USA	2012	Swimming	Swimming Men's 400 metres Individual Medley	NULL
22	Michael Fred Phelps	USA	2012	Swimming	Swimming Men's 200 metres Butterfly	Silver
23	Michael Fred Phelps	USA	2012	Swimming	Swimming Men's 4 x 200 metres Freestyle Relay	Gold
24	Michael Fred Phelps	USA	2012	Swimming	Swimming Men's 4 x 100 metres Medley Relay	Gold
25	Michael Fred Phelps	USA	2016	Swimming	Swimming Men's 100 metres Butterfly	Silver
26	Michael Fred Phelps	USA	2016	Swimming	Swimming Men's 200 metres Butterfly	Gold
27	Michael Fred Phelps	USA	2016	Swimming	Swimming Men's 4 x 100 metres Freestyle Relay	Gold
28	Michael Fred Phelps	USA	2016	Swimming	Swimming Men's 200 metres Individual Medley	Gold

4.2. Procedimiento: `sp_ConsultarPais`

Recibe como parámetro de entrada el nombre o código del país y ejecuta múltiples consultas de validación.

- **Medallero Deduplicado:** Aplica lógica condicional para contar de manera individual las medallas de disciplinas convencionales (`es_por_equipo = 0`), y utiliza cláusulas `DISTINCT` sobre eventos de equipo (`es_por_equipo = 1`) para evitar la sobrestimación de preseas en el medallero total.
- **Historial de Sedes:** Cruza la información del país con las entidades `SEDE` y `EDICION_JUEGOS` para desplegar la ciudad y el año en que ha sido anfitrión, indicando mediante un bloque `IF NOT EXISTS` si la nación nunca ha sido sede.




5. Consultas de Validación y Evidencias

Durante las pruebas de control de calidad sobre la base de datos restaurada (`OlimpiadasDB.bak`), se ejecutaron las siguientes consultas analíticas demostrando la coherencia del modelo:


A. Medallistas por País Específico (Ej. Guatemala)

Demostración del uso de llaves foráneas (`INNER JOIN`) filtrando por código NOC y descartando participaciones sin medalla.



B. El Medallero Real e Histórico

Validación estricta de países con mayor cantidad de oros oficiales en la historia, agrupando por edición y evento para confirmar que los deportes colectivos suman una sola medalla por país.



C. Ausencia de Datos (Uso de NULL)

Comprobación de registro de atletas que compitieron pero no obtuvieron medalla, evidenciando que el motor procesa el estado de ausencia correctamente con cláusulas **IS NULL**.

The screenshot shows a SQL query executed in SQL Server Enterprise Manager. The query is designed to find athletes from Guatemala who participated in events but did not win a medal. The query uses a series of INNER JOINs to link the athlete, event, and edition tables, and a WHERE clause to filter for athletes from Guatemala and those who did not win a medal (IS NULL).

```
USE OlimpiadasDB;
GO

-- 3. MANEJO DE NULOS (Ausencia de datos)
-- Atletas de Guatemala que participaron pero no ganaron medalla
SELECT DISTINCT
  A.nombre AS Atleta,
  E.nombre AS Evento,
  EJ.anio AS Anio
FROM PARTICIPACION PAR
INNER JOIN ATLETA A ON PAR.id_atleta = A.id_atleta
INNER JOIN PAIS P ON PAR.id_pais_representado = P.id_pais
INNER JOIN EVENTO E ON PAR.id_evento = E.id_evento
INNER JOIN EDICION_JUEGOS EJ ON PAR.id_edicion = EJ.id_edicion
WHERE P.codigo_noc = 'GUA' AND PAR.medalla IS NULL;
```

The results pane shows a list of athletes from Guatemala who participated in various events but did not win a medal. The results are as follows:

Atleta	Evento	Anio
Adrián Ochoa Pantoja Gomez	Football Men's Football	1980
Alberto de Suenman	Rowing Men's Coxless Pair	1980
Alberto Lopez	400 metres, Men (Olympic)	1984
Alberto Lopez	800 metres, Men (Olympic)	1984
Alberto Lopez Daila	Athletics Men's 400 metres	1984
Alberto Lopez Daila	Athletics Men's 800 metres	1984
Alberto Lopez Oliva	Football Men's Football	1980
Alfonso Ocho Obregon	Football Men's Football	1980
Alfredo Arvelo	Marathon, Men (Olympic)	2004
Alfredo Arvelo	Marathon, Men (Olympic)	2008
Alfredo Arvelo Reyes	Athletics Men's Marathon	2004
Alfredo Arvelo Reyes	Athletics Men's Marathon	2008
Alfredo Mury	Free Rifle, Three Positions, 300 metres, Men (Olympic)	1962
Alfredo Mury	Small Bore Rifle, Prone, 50 metres, Men (Olympic)	1962
Alfredo Mury Berta	Shooting Men's Free Rifle, Three Positions, 300	1962
Alfredo Mury Berta	Shooting Men's Small Bore Rifle, Prone, 50 metres	1962
Alan Kenny Wellman	Football Men's Football	1976
Alan Kenny Wellman	Football Men's Football	1980
Ana Sofia Gomez Ponce	Gymnastics Women's Balance Beam	2012
Ana Sofia Gomez Ponce	Gymnastics Women's Balance Beam	2016
Ana Sofia Gomez Ponce	Gymnastics Women's Floor Exercise	2012
Ana Sofia Gomez Ponce	Gymnastics Women's Individual All Around	2012
Ana Sofia Gomez Ponce	Gymnastics Women's Individual All Around	2016
Ana Sofia Gomez Ponce	Gymnastics Women's Uneven Bars	2012
Ana Sofia Gomez Ponce	Gymnastics Women's Uneven Bars	2016
Andrea Aldana	One Person Dinghy, Women (Olympic)	2012
Andrea Gomez Aldana Bernat	Sailing Women's One Person Dinghy	2012

The screenshot shows a SQL query executed in SQL Server Enterprise Manager. The query is designed to find the top 5 countries by the number of gold medals won. The query uses a series of JOINs to link the participation, athlete, and event tables, and a WHERE clause to filter for gold medals. The results are ordered by the number of gold medals in descending order.

```
USE OlimpiadasDB;
GO

-- 1. EL MEDALLERO REAL (Deduplicando eventos por equipo para no inflar medallas)
-- Muestra el Top 5 de paises con más medallas de Oro oficiales.
SELECT TOP 5
  P.nombre AS Pais,
  COUNT(DISTINCT CONCAT(PAR.id_edicion, '-', PAR.id_evento)) AS Oros_Oficiales
FROM PARTICIPACION PAR
INNER JOIN PAIS P ON PAR.id_pais_representado = P.id_pais
WHERE PAR.medalla = 'Gold'
GROUP BY P.nombre
ORDER BY Oros_Oficiales DESC;
```

The results pane shows a list of the top 5 countries by the number of gold medals won. The results are as follows:

Pais	Oros_Oficiales
USA	1141
Russia	800
Germany	494
UK	385
France	385