

Documentación del Proyecto

Fase 1: Base de Datos

Olimpiadas (1896 - 2024)

Universidad de San Carlos de Guatemala

Facultad de Ingeniería - Escuela de Ciencias y Sistemas

Sistemas de Bases de Datos 2 - 2do. Semestre 2026

Grupo: #16

Integrantes:

- Marcelo André Juárez Alfaro - 202010367
- Carlos David de León Barrios - 202112109
- Angel Rafael Barrios González - 202300733

1. Introducción y Alcance

El presente proyecto tiene como objetivo la integración, limpieza y consolidación de la información histórica de los Juegos Olímpicos desde Atenas 1896 hasta París 2024. Los datos provienen de cuatro fuentes heterogéneas principales: repositorios de Kaggle, datasets de Keith Galli y DataCamp, tomando como validación de calidad el sitio oficial olympics.com. La arquitectura de solución emplea Python (mediante Jupyter Notebooks) para los procesos de Extracción, Transformación y Carga (ETL) desde los archivos crudos, y Microsoft SQL Server para el alojamiento, persistencia y consulta analítica de la base de datos relacional resultante.

2. Modelo Entidad-Relación (ER)

El modelado de datos se diseñó bajo un enfoque relacional pragmático orientado a esquema de estrella/copo de nieve, minimizando la hiper-normalización para evitar uniones (**JOIN**) excesivas y garantizando la integridad referencial.


El núcleo del modelo es la tabla central de hechos **PARTICIPACION**, la cual se encuentra rodeada por entidades dimensionales maestras: **ATLETA**, **PAIS**, **SEDE**,

EDICION_JUEGOS, EVENTO, DEPORTE, POBLACION_PAIS y FUENTE_DATOS.

DIAGRAMA ER

GRUPO #16

Marcelo Andres Juarez Alfaro
Carlos David de León Barrios
Angel Rafael Barrios González



3. Proceso ETL y Limpieza de Datos

La limpieza de la información cruda se gestionó mediante los archivos `etl_carga.ipynb` y `auditoria.ipynb`, resolviendo los siguientes desafíos críticos de los datos origen:

- Resolución de Colisiones de Identificadores:** Debido a que distintas fuentes (ej. Kaggle vs. Keith Galli) poseían diferentes atletas con el mismo `ID` original, se implementó un campo de llave primaria autoincremental (`id_atleta INT IDENTITY(1,1)`) en la tabla final, resguardando los códigos originales en columnas de trazabilidad (`id_origen_bios`, `id_origen_kaggle`).


- **Homologación de Códigos Geográficos:** Se integraron tanto los códigos internacionales de tres letras del Banco Mundial (`codigo_iso3`) como los del Comité Olímpico (`codigo_noc`) en la entidad `PAIS` para mantener la integridad relacional con las estadísticas de población y sedes.
- **Manejo de Valores Nulos:** Los datos faltantes de origen (estatura, peso, edad o género) se conservaron e ingresaron en la base de datos como valores `NULL` estrictos en lugar de cadenas vacías o ceros.

4. Implementación de Procedimientos Almacenados (Stored Procedures)

Se implementaron y compilaron en SQL Server los requerimientos analíticos solicitados en el enunciado:

4.1. Procedimiento: `sp_ConsultarAtleta`

Permite buscar un atleta por su nombre y muestra de manera unificada el país que representó, el año de edición, el deporte, la prueba específica y la medalla obtenida. Se incluyen parámetros opcionales para filtrar resultados por deporte, país o año.



4.2. Procedimiento: `sp_ConsultarPais`

Recibe como parámetro de entrada el nombre o código del país y ejecuta múltiples consultas de validación.

- **Medallero Deduplicado:** Aplica lógica condicional para contar de manera individual las medallas de disciplinas convencionales (`es_por_equipo = 0`), y utiliza cláusulas `DISTINCT` sobre eventos de equipo (`es_por_equipo = 1`) para evitar la sobrestimación de preseas en el medallero total.
- **Historial de Sedes:** Cruza la información del país con las entidades `SEDE` y `EDICION_JUEGOS` para desplegar la ciudad y el año en que ha sido anfitrión, indicando mediante un bloque `IF NOT EXISTS` si la nación nunca ha sido sede.

tests.sql - ...L\admin (55) 04_Consultas_...L\admin (75) 03_Stored_Pr...L\admin (69)

```

1  -- PRUEBA DE STORED PROCEDURES (Para ejecutar en vivo)
2  -- Ejecutar buscando un atleta específico
3  -- EXEC sp_ConsultarAtleta @nombre_atleta = 'Michael Fred Phelps';
4
5  -- Ejecutar buscando un país (Ejemplo: Estados Unidos)
6  EXEC sp_ConsultarPais @codigo_o_nombre = 'USA';

```

121 % No se encontraron problemas.

Resultados Mensajes

	NombrePais	CodigoOlimpico	TotalOro	TotalPlata	TotalBronce	TotalMedallas
1	USA	USA	1817	1453	1268	4538

	CiudadSede	AnioSede	Temporada
1	St. Louis	1904	Summer
2	Los Angeles	1932	Summer
3	Lake Placid	1932	Winter
4	Squaw Valley	1960	Winter
5	Lake Placid	1980	Winter
6	Los Angeles	1984	Summer
7	Atlanta	1996	Summer
8	Salt Lake City	2002	Winter

5. Consultas de Validación y Evidencias

Durante las pruebas de control de calidad sobre la base de datos restaurada (`OlimpiadasDB.bak`), se ejecutaron las siguientes consultas analíticas demostrando la coherencia del modelo:

A. Medallistas por País Específico (Ej. Guatemala)

Demostración del uso de llaves foráneas (`INNER JOIN`) filtrando por código NOC y descartando participaciones sin medalla.

```

1  USE OlimpiadasDB;
2  GO
3
4  -- Medallistas de Guatemala (todas las medallas obtenidas)
5  SELECT
6      A.nombre AS Atleta,
7      EJ.anio AS Anio,
8      EV.nombre AS Evento,
9      PAR.medalla AS Medalla
10 FROM PARTICIPACION PAR
11 INNER JOIN ATLETA A ON A.id_atleta = PAR.id_atleta
12 INNER JOIN PAIS P ON P.id_pais = PAR.id_pais_representado
13 INNER JOIN EDICION_JUEGOS EJ ON EJ.id_edicion = PAR.id_edicion
14 INNER JOIN EVENTO EV ON EV.id_evento = PAR.id_evento
15 WHERE P.codigo_noc = 'GUA' AND PAR.medalla IS NOT NULL
16 ORDER BY EJ.anio;

```

121 % No se encontraron problemas.

Resultados Mensajes

	Atleta	Anio	Evento	Medalla
1	Erick Bernab Barrondo Garca	2012	Athletics Men's 20 kilometres Walk	Silver
2	Erick Barrondo	2012	20 kilometres Race Walk, Men (Olympic)	Silver

B. El Medallero Real e Histórico

Validación estricta de países con mayor cantidad de oros oficiales en la historia, agrupando por edición y evento para confirmar que los deportes colectivos suman una sola medalla por país.

The screenshot shows a SQL query execution window with the following SQL code:

```
1 USE OlimpiadasDB;
2 GO
3
4 -- 1. EL MEDALLERO REAL (Deduplicando eventos por equipo para no inflar medallas)
5 -- Muestra el Top 5 de países con más medallas de ORO oficiales.
6 SELECT TOP 5
7     P.nombre AS Pais,
8     COUNT(DISTINCT CONCAT(PAR.id_edicion, '-', PAR.id_evento)) AS Oros_Oficiales
9 FROM PARTICIPACION PAR
10 INNER JOIN PAIS P ON PAR.id_pais_representado = P.id_pais
11 WHERE PAR.medalla = 'Gold'
12 GROUP BY P.nombre
13 ORDER BY Oros_Oficiales DESC;
```

Below the query, the results are displayed in a table:

	Pais	Oros_Oficiales
1	USA	1784
2	Russia	1141
3	Germany	800
4	UK	494
5	France	385

C. Ausencia de Datos (Uso de NULL)

Comprobación de registro de atletas que compitieron pero no obtuvieron medalla, evidenciando que el motor procesa el estado de ausencia correctamente con cláusulas `IS NULL`.

tests.sql - ...L\admin (55)
04_Consultas_...L\admin (75)
03_Stored_Pr...L\admin (69)

```

1  USE OlimpiadasDB;
2  GO
3
4  -- 3. MANEJO DE NULOS (Ausencia de datos)
5  -- Atletas de Guatemala que participaron pero no ganaron medalla
6  SELECT DISTINCT
7      A.nombre AS Atleta,
8      E.nombre AS Evento,
9      EJ.anio AS Anio
10 FROM PARTICIPACION PAR
11 INNER JOIN ATLETA A ON PAR.id_atleta = A.id_atleta
12 INNER JOIN PAIS P ON PAR.id_pais_representado = P.id_pais
13 INNER JOIN EVENTO E ON PAR.id_evento = E.id_evento
14 INNER JOIN EDICION_JUEGOS EJ ON PAR.id_edicion = EJ.id_edicion
15 WHERE P.codigo_noc = 'GUA' AND PAR.medalla IS NULL;

```

121 %
No se encontraron problemas.

Resultados

Mensajes

	Atleta	Evento	Anio
1	Adn Onelio Paniagua Gmez	Football Men's Football	1988
2	Alberik de Suremain	Rowing Men's Coxless Pairs	1980
3	Alberto López	400 metres, Men (Olympic)	1984
4	Alberto López	800 metres, Men (Olympic)	1984
5	Alberto Lpez Davila	Athletics Men's 400 metres	1984
6	Alberto Lpez Davila	Athletics Men's 800 metres	1984
7	Alberto Lpez Oliva	Football Men's Football	1968
8	Alejandro Ortiz Obregón	Football Men's Football	1988
9	Alfredo Arévalo	Marathon, Men (Olympic)	2004
10	Alfredo Arévalo	Marathon, Men (Olympic)	2008
11	Alfredo Arvalo Reyes	Athletics Men's Marathon	2004
12	Alfredo Arvalo Reyes	Athletics Men's Marathon	2008
13	Alfredo Mury	Free Rifle, Three Positions, 300 metres, Men (Oly...	1952
14	Alfredo Mury	Small-Bore Rifle, Prone, 50 metres, Men (Olympic)	1952
15	Alfredo Mury Bentz	Shooting Men's Free Rifle, Three Positions, 300 ...	1952
16	Alfredo Mury Bentz	Shooting Men's Small-Bore Rifle, Prone, 50 metres	1952
17	Allan Kenny Wellman	Football Men's Football	1976
18	Allan Kenny Wellman	Football Men's Football	1988
19	Ana Sofa Gmez Porras	Gymnastics Women's Balance Beam	2012
20	Ana Sofa Gmez Porras	Gymnastics Women's Balance Beam	2016
21	Ana Sofa Gmez Porras	Gymnastics Women's Floor Exercise	2012
22	Ana Sofa Gmez Porras	Gymnastics Women's Floor Exercise	2016
23	Ana Sofa Gmez Porras	Gymnastics Women's Individual All-Around	2012
24	Ana Sofa Gmez Porras	Gymnastics Women's Individual All-Around	2016
25	Ana Sofa Gmez Porras	Gymnastics Women's Uneven Bars	2012
26	Ana Sofa Gmez Porras	Gymnastics Women's Uneven Bars	2016
27	Andrea Aldana	One Person Dinghy, Women (Olympic)	2012
28	Andrea Dennise Aldana B...	Sailing Women's One Person Dinghy	2012
29	Andrei Gheorhe	Modern Pentathlon Men's Individual	2012

Consulta ejecutada correctamente.